

Raport Końcowy

Selekcja i optymalizacja portfela spółek giełdowych z
wykorzystaniem symulacji Monte Carlo
Projekt Indywidualny

Michał Ludwiczak

12 czerwca 2026 r.

Spis treści


1	Wstęp	2
1.1	Benchmark	2
1.2	Inwestorzy VS Indeks	5
1.3	Cel projektu	6
1.4	Założenia	6
2	Dane	7
2.1	Wymagania względem danych	7
2.2	Dane o składzie indeksu	9
2.2.1	Dane o aktualnym składzie indeksu	9
2.2.2	Dane o historycznym składzie indeksu	9
2.3	Dane cenowe	11
2.3.1	Dane cenowe z Yahoo Finance	11
2.3.2	Dane cenowe z EODHD	20
2.3.3	Połączenie danych z Yahoo Finance i EODHD	22
2.3.4	Uzupełnienie brakujących danych	22
3	Tworzenie strategii	25
3.1	Strategia losowa	26
3.2	Strategia Monte Carlo	26
3.3	Strategia najwyższego współczynnika Sharpe'a	28
3.4	Porównanie strategii	29
4	Podsumowanie	30
4.1	Obserwacje, ograniczenia i wnioski	30
4.2	Przemyślenia i rozszerzenia	31

1 Wstęp

Projekt jest realizowany w ramach przedmiotu Projekt Indywidualny na Politechnice Warszawskiej, na kierunku Informatyka Stosowana. Dotyczy analizy oraz optymalizacji portfela spółek giełdowych z wykorzystaniem symulacji Monte Carlo.

1.1 Benchmark


Wyniki analizowanych strategii będą porównywane z indeksem **S&P 500** (Standard & Poor's 500) [1], który jest jednym z najczęściej stosowanych benchmarków dla rynku akcji w Stanach Zjednoczonych. Indeks ten reprezentuje szeroki przekrój dużych i płynnych spółek, a jego wyniki są często traktowane jako przybliżenie zachowania całego rynku akcji (reprezentuje około 80% kapitalizacji). Ze względu na charakter globalny dużej większości składowych indeksu, indeks ten nie tylko powinien dobrze odzwierciedlać gospodarkę Stanów Zjednoczonych, ale również i gospodarkę globalną.



Rysunek 1: 50-letni wykres indeksu S&P 500 [2].

Indeks jest również odpowiednio zdywersyfikowany – spółki należą do różnych sektorów, jednak dominujący jest sektor technologiczny, co wynika z faktu, że S&P 500 jest indeksowany kapitalizacją rynkową, a największe spółki technologiczne mają największe wagi, co znacząco wpływa na wycenę całego indeksu.

S&P 500 components by sector




Rysunek 2: Skład sektorowy indeksu S&P 500 stan na styczeń 2025 [3].

Największe 7 spółek w indeksie S&P 500 są określane jako Wspaniała Siódemka (The Magnificent Seven). Ich znaczący udział w kapitalizacji indeksu sprawia, że mają one nieproporcjonalnie duży wpływ na jego wyniki, co przedstawiono na rysunku 3.

Mag 7 Market Share of S&P 500

The market cap of the Mag 7 compared to the rest of the S&P 500. All measurements in trillions \$USD.

Remaining 493 Companies Nvidia Apple Alphabet Microsoft Amazon Meta Tesla



Rysunek 3: Wpływ „Wspaniałej Siódemki” na indeks S&P 500 [4].

Istnieje również wersja indeksu S&P 500 z kwartalnym równoważeniem wag spółek (**S&P 500 equal-weighted**), w której każda spółka ma taki sam udział w indeksie, niezależnie od kapitalizacji rynkowej. W tej wersji dominacja największych spółek technologicznych jest znacznie mniejsza, a wpływ mniejszych spółek na wartość indeksu staje się bardziej widoczny.

Porównanie z S&P 500 pozwala ocenić, czy zastosowane metody selekcji spółek oraz konstrukcji portfela prowadzą do rezultatów lepszych lub porównywalnych z prostą strategią inwestowania w szeroki indeks rynkowy. Jest to istotne, ponieważ wiele aktywnych strategii inwestycyjnych w długim okresie nie jest w stanie konsekwentnie osiągać wyników lepszych od indeksów rynkowych. Oczywiście wszystkie stopy zwrotu, zarówno indeksu, jak i portfeli, są wyrażone w wartościach nominalnych i obciążone wpływem inflacji, co oznacza, że realne stopy zwrotu są niższe. Jednak przy porównaniu z benchmarkiem względny wynik pozostaje niezmienny, dlatego wpływ inflacji nie zmienia wniosków dotyczących efektywności strategii. Wpływ podatków także nie jest uwzględniany, co pozwala skupić się wyłącznie na po-


równaniu względnej wydajności portfela względem indeksu.

Years Averaged (as of the end of February, 2026)	Stock Market Average Return per Year (Dividends Reinvested)	Average Return with Dividends Reinvested & Inflation Adjusted
150 Years	9.43%	6.98%
100 Years	10.42%	7.27%
50 Years	11.71%	7.84%
30 Years	10.12%	7.43%
20 Years	10.84%	8.15%
10 Years	15.62%	12.02%
5 Years	13.72%	8.99%

Rysunek 4: Średnie roczne stopy zwrotu indeksu S&P 500 [5].

1.2 Inwestorzy VS Indeks

W teorii, odpowiednio dobrany portfel powinien uzyskać lepsze wyniki niż sam indeks S&P 500 poprzez selekcję spółek o lepszych perspektywach oraz optymalną alokację wag. W praktyce jest to trudne, na co wskazują dane raportu **SPIVA® U.S. Year-End 2025** [6] - w 2025 roku 79% wszystkich aktywnych funduszy akcyjnych o dużej kapitalizacji w Stanach Zjednoczonych osiągnęło wyniki gorsze od indeksu S&P 500.



Rysunek 5: Wyniki funduszy aktywnych względem indeksu S&P 500 [6].

Od 2001 do 2025 tylko w latach 2005, 2007 i 2009 udało się pobić S&P

500 większości z nich.

Inwestorzy indywidualni również często nie osiągają wyników lepszych od indeksu. Według raportu **DALBAR – Quantitative Analysis of Investor Behavior (QAIB) 2024** [7], przeciętny inwestor giełdowy uzyskał stopę zwrotu na poziomie 16,54%, podczas gdy indeks S&P 500 osiągnął 25,02%. Różnica 848 punktów bazowych była drugą największą w ciągu ostatniej dekady, co pokazuje, że większość inwestorów detalicznych systematycznie nie dorównuje wynikowi szerokiego rynku.

Badania akademickie, takie jak **Trading Is Hazardous to Your Wealth (Berkeley)** [8], wskazują, że realne decyzje inwestorów indywidualnych – częste kupno i sprzedaż akcji, próby „timingu” rynku oraz reakcje emocjonalne – znacząco obniżają ich wyniki w porównaniu z prostą strategią buy-and-hold indeksu S&P 500. W przypadku inwestorów indywidualnych często dochodzi do mylenia roli **inwestora** z rolą **spekulanta**, jak wskazuje Benjamin Graham [9] w klasycznej literaturze inwestycyjnej: wielu uczestników rynku podejmuje decyzje krótkoterminowe, oczekując szybkich zysków, zamiast koncentrować się na długoterminowej wartości spółki.

1.3 Cel projektu

Celem projektu nie jest bezwzględne pobicie indeksu, lecz racjonalna selekcja i optymalizacja portfela spółek w oparciu o dane historyczne tak aby uzyskać efektywność porównywalną z benchmarkiem przy kontrolowanym ryzyku. Projekt ma również na celu ukazanie złożoności testowania strategii inwestycyjnych oraz wpływu jakości danych na uzyskiwane wyniki. Nie zakłada on stworzenia strategii konsekwentnie pokonującej szeroki rynek akcji.

Projekt ma charakter badawczo-eksperymentalny. Efekty jego realizacji pozwolą lepiej zrozumieć ograniczenia strategii aktywnych inwestorów oraz ich rzeczywistą skuteczność w porównaniu z szerokim indeksem rynkowym.

1.4 Założenia

Projekt opiera się na dwóch głównych założeniach:

1. W teorii, odpowiednio wybrany podzbiór spółek z indeksu S&P 500 powinien wykazywać wyniki lepsze niż sam indeks, dzięki selekcji spółek o wyższych perspektywach.
2. Próba wykorzystania wszystkich spółek światowych (kolejnym benchmarkiem byłby z pewnością MSCI World Index [10]) do budowy strategii portfela byłaby nadmiernie złożona, zarówno pod względem obliczeniowym, jak i dostępności danych.

W związku z tym, analizowane spółki pochodzą wyłącznie z indeksu S&P 500, co pozwala na realistyczne i porównywalne badanie różnych strategii inwestycyjnych przy zachowaniu spójności danych historycznych.

2 Dane

Dane są kluczowym elementem projektu. W ramach analiz wykorzystywane są trzy główne typy danych:


- **Skład indeksu S&P 500** – portfele będą tworzone ze spółek wchodzących w skład tego indeksu.
- **Ceny akcji** – niezbędne do symulacji Monte Carlo oraz do narzędzi analizy technicznej.
- **Dane techniczne** – wskaźniki wyliczane na podstawie historycznych cen, używane w strategiach opartych na analizie technicznej.

2.1 Wymagania względem danych

1. Wszystkie dane muszą mieć charakter **historyczny**, aby możliwe było poprawne testowanie strategii i modeli w oparciu o warunki rynkowe z przeszłości. Oznacza to, że dane powinny odzwierciedlać stan wiedzy w danym momencie historycznym. Pozwala to uniknąć tzw. **błędu wyprzedzania** informacji (look-ahead bias), który polega na wykorzystaniu w teście danych niedostępnych w momencie podejmowania decyzji, w tym kontekście decyzji inwestycyjnych o składzie portfeli.
2. Dane powinny obejmować odpowiednio **długi okres historyczny**, umożliwiający testowanie strategii inwestycyjnych w dłuższej perspektywie, a nie tylko krótkoterminowych ruchów rynkowych. Inwestowanie to nie spekulacja, wspominając ponownie Grahama.
3. Dane muszą obejmować również spółki, które wypadły z indeksu, lub **spółki, które już nie istnieją**, czyli takie, w których wystąpiła jedna z poniższych sytuacji:
 - bankructwo
 - fuzja lub przejęcie (spółka została wchłonięta przez inną)
 - delisting / wycofanie z giełdy (np. zmiana statusu prywatnego lub restrukturyzacja)

Jest to konieczne, aby uniknąć **błędu przeżywalności** (survivorship bias), czyli sytuacji, w której uwzględnia się wyłącznie spółki trwałe. Błąd przeżywalności i błąd wyprzedzania w praktyce mają podobny efekt – w backtestingu modele lub strategie dysponują informacjami o przyszłości, które w rzeczywistości nie były dostępne w danym momencie. Skutkuje to zawyżeniem stóp zwrotu i efektywności strategii, prowadząc do mylnych wniosków o ich skuteczności.

Poniższa mapa ciepła przedstawia komponenty indeksu S&P 500 z ich 10-letnimi stopami zwrotu. Średnia ważona stopa zwrotu tych spółek jest znacznie wyższa niż 10-letnia stopa zwrotu samego indeksu, którego skład zmieniał się w tym czasie. Ten przykład doskonale ilustruje, jak błąd przeżywalności może nierealistycznie zawyżyć wyniki.



Rysunek 6: 10-letnie stopy zwrotu komponentów S&P 500 ETF (2026.03.24) [11].

4. Dane muszą być **skorygowane o splity akcji** (podział akcji zwiększający ich liczbę w obrocie) oraz o **dywidendy** (część zysku przedsiębiorstwa wypłacana akcjonariuszom).
5. Dane cenowe powinny mieć **spójną częstotliwość** (np. dzienne EOD, tygodniowe, miesięczne), aby umożliwić porównywalne analizy.
6. Dane powinny być **wysokiej jakości** - wolne od błędów, braków oraz duplikatów.

2.2 Dane o składzie indeksu

Do pozyskania danych o składzie indeksu S&P 500 przydatny jest projekt [fja05680/sp500](#) [12] na GitHub. Zawiera on zarówno aktualną, jak i historyczną listę spółek wchodzących w skład indeksu oraz przykładowe notebooki umożliwiające pobranie tych danych. Projekt jest regularnie aktualizowany, co zapewnia dostęp do aktualnych informacji o składzie indeksu. Jednakże, jak sam autor podkreśla, nie ma gwarancji, iż wszystkie dane są w 100% prawidłowe.

2.2.1 Dane o aktualnym składzie indeksu

Aktualny skład indeksu jest pozyskiwany z [Wikipedii](#) [13].


Tabela 1: Fragment danych o spółkach wchodzących w skład indeksu S&P 500.

	Symbol	Security	GICS Sector	GICS Sub-Industry	Headquarters Location	Date added	CIK	Founded
0	MMM	3M	Industrials	Industrial Conglomerates	Saint Paul, Minnesota	1957-03-04	66740	1902
1	AOS	A. O. Smith	Industrials	Building Products	Milwaukee, Wisconsin	2017-07-26	91142	1916
...	...	...	...	...	...	...	...	...
501	ZBH	Zimmer Biomet	Health Care	Health Care Equipment	Warsaw, Indiana	2001-08-07	1136869	1927
502	ZTS	Zoetis	Health Care	Pharmaceuticals	Parsippany, New Jersey	2013-06-21	1555280	1952

2.2.2 Dane o historycznym składzie indeksu


Historyczny skład indeksu jest budowany na podstawie pliku S&P 500 Historical Components & Changes, udostępnionego wraz z książką *Trading Evolved* [14] autorstwa Andreas Clenow, który obejmuje okres 1996–2019. Następnie dane są ręcznie aktualizowane o zmiany po 2019 roku na podstawie informacji z Wikipedia oraz dodatkowych źródeł internetowych, ponieważ sekcja „Selected Changes” nie zawiera pełnej historii modyfikacji indeksu. Końcowy zbiór danych powstaje poprzez scalenie oryginalnego pliku z późniejszymi zmianami oraz wykonanie podstawowego czyszczenia danych, co pozwala uzyskać aktualny plik obejmujący pełną historię zmian składu indeksu.

Na podstawie poniższego wykresu przedstawiającego liczbę spółek wchodzących do indeksu na początku każdego roku widać, że mimo nazwy „S&P 500” liczba komponentów nie zawsze wynosi dokładnie 500.




Rysunek 7: Liczba spółek w indeksie S&P 500 na początku każdego roku.

Na przestrzeni ostatnich 30 lat można zauważyć spadek rotacji w indeksie w porównaniu z okresem bańki internetowej w 2000 roku oraz latami poprzedzającymi kryzys 2008 roku, a w ciągu ostatnich 15 lat rotacja ustabilizowała się na poziomie około 20 spółek rocznie. Zmiany w składzie indeksu oraz częstotliwość selekcji będą miały wpływ na skład tworzonych portfeli.



Rysunek 8: Roczna liczba spółek wchodzących i wychodzących z indeksu S&P 500.



Rysunek 9: Kumulatywna liczba unikalnych spółek wchodzących w skład indeksu S&P 500.

2.3 Dane cenowe

Do selekcji spółek do portfela z wykorzystaniem analizy technicznej w dłuższym terminie wystarczają wartości uzyskane pod koniec sesji każdego dnia (**End-of-Day, EOD**). Ponieważ dane muszą obejmować również spółki, które już nie istnieją, aby uniknąć błędów badawczych, darmowe źródła często okazują się niewystarczające. W praktyce można przyjąć dwa podejścia:

- pobranie danych cenowych z darmowych źródeł i uzupełnienie brakujących danych profesjonalnym dostawcą,
- pobranie wszystkich danych bezpośrednio od profesjonalnego dostawcy.

W tym projekcie wybrane zostało pierwsze podejście, aby zwizualizować potencjalny wpływ brakujących lub niekompletnych danych na wyniki analizy.

2.3.1 Dane cenowe z Yahoo Finance

Najpopularniejszą opcją pozyskania danych cenowych jest korzystanie z **Yahoo Finance** [15], np. poprzez bibliotekę **yfinance** [16] w Pythonie, która umożliwia pobranie danych historycznych spółek wraz z cenami skorygowanymi o splits i dywidendy.

Uzyskanie danych z pojedynczej spółki

Poniżej przedstawiono przykładowe użycie tej biblioteki w celu uzyskania historii cen akcji spółki Apple (AAPL). Dane cenowe zamknięcia (**Adj Close**) są już skorygowane o dywidendy.


```
1 ticker = "AAPL"
2 apple = yf.download(ticker, period="max", actions=True,
    auto_adjust=False)
```

Listing 1: Pobieranie danych historycznych dla AAPL

Poniższy fragment danych – dzień przed, w dniu oraz dzień po splicie akcji – pokazuje, że ceny w danych historycznych uwzględniają już split.

Tabela 2: Fragment danych Apple (AAPL) wokół splitu akcji (4:1) z dnia 31.08.2020.

Date	Open	Adj Close	Dividends	Stock Splits
2020-08-28	126.0125	121.0600	0.0	0.0
2020-08-31	127.5800	125.1654	0.0	4.0
2020-09-01	132.7600	130.1510	0.0	0.0



Rysunek 10: Historia cen akcji Apple (AAPL).

Uzyskanie danych o indeksie


Na platformie Yahoo Finance dostępne są różne tickery reprezentujące indeks S&P 500, które różnią się sposobem uwzględniania dywidend:

- **SP500 (^GSPC, S&P 500)** – indeks cenowy (*price return*), uwzględniający wyłącznie zmiany cen akcji spółek wchodzących w skład indeksu.
- **SP500TR (^SP500TR, S&P 500 Total Return)** – indeks dochodowy (*total return*), uwzględniający zarówno zmiany cen, jak i reinwestowane dywidendy.
- **ETF (CSPX.L, iShares Core S&P 500 UCITS ETF Acc)** – fundusz ETF replikujący indeks S&P 500 w sposób fizyczny, akumulujący dywidendy (reinvestowane wewnątrz funduszu), stanowiący przybliżenie rzeczywistej stopy zwrotu inwestora.


Zestawienie tych trzech instrumentów pozwala porównać:

- wpływ dywidend na długoterminową stopę zwrotu,
- różnice między indeksem teoretycznym a rzeczywistym instrumentem inwestycyjnym,
- dokładność odwzorowania indeksu przez ETF (tzw. *tracking error*).

Ich dane w kolumnach Close i Adj Close są jednakowe.



Rysunek 11: Porównanie notowań S&P 500, S&P 500 Total Return oraz ETF dla kolumny Close (skala logarytmiczna).



Rysunek 12: Porównanie notowań S&P 500, S&P 500 Total Return oraz ETF dla kolumny Adj Close (skala logarytmiczna).

Widzimy nie tylko różnicę między indeksem uwzględniającym dywidendy a tym nieuwzględniającym, ale także między indeksem total return a odpowiadającym mu ETF-em, który zwykle osiąga nieco niższe wyniki z powodu błędu odwzorowania (*tracking error*).

Hybrydowy indeks S&P 500

Sam ETF nie jest więc wystarczający jako pełny benchmark historyczny, ponieważ jego najdłuższa porównywalna historia (dla ETF-u akumulującego dywidendy) rozpoczyna się dopiero około 2010 roku. Z tego powodu w analizie potrzebne są oba szeregi: **SP500TR** (długi horyzont historyczny i referencja total return) oraz **benchmark hybrydowy** (odwzorowanie realnych warunków inwestora poprzez uwzględnienie tracking error i wykorzystanie rzeczywistych notowań ETF tam, gdzie są dostępne).

W praktyce: SP500TR odpowiada za część historyczną (przed debiutem ETF), a hybryda zapewnia ciągłość serii i porównywalność wyników z realnym instrumentem inwestycyjnym.

Do konstrukcji hybrydowego indeksu rozważono podejścia oparte na **splincingu**, tj. łączeniu fragmentów szeregów czasowych w jedną spójną serię. Przyjęto, że w okresie dostępności ETF-u indeks hybrydowy odpowiada jego rzeczywistym notowaniom, natomiast wcześniejsze obserwacje są rekonstruowane na podstawie indeksu SP500TR.

Rozważono następujące podejścia:

1. **Proste skalowanie** — dane SP500TR są skalowane tak, aby ich wartość w punkcie łączenia była zgodna z wartością ETF-u.
2. **Bezwzględna różnica odwzorowania (tracking difference)** — w okresie wspólnym estymowana jest średnia różnica stóp zwrotu:

$$\overline{\text{TD}} = \frac{1}{T} \sum_{t=1}^T (R_{\text{TR}} - R_{\text{ETF}}),$$

która następnie koryguje historyczne stopy zwrotu:

$$r_{\text{HYB}} = R_{\text{TR}} - \overline{\text{TD}}.$$

Podejście to pomija jednak kumulatywny charakter błędu odwzorowania oraz jego proporcjonalność do poziomu cen.

3. **Względna różnica odwzorowania** — w okresie wspólnym estymowana jest relatywna różnica wyników ETF względem indeksu:

$$TD_{\text{annual}} = \left(\frac{R_{\text{TR}}}{R_{\text{ETF}}} \right)^{\frac{252}{N}} - 1,$$

gdzie R_{TR} i R_{ETF} oznaczają całkowite stopy zwrotu, a N liczbę dni sesyjnych.


Otrzymany parametr interpretowany jest jako średni roczny koszt odwzorowania i przekształcany do dziennego czynnika, który jest następnie kumulowany wstecznie:

$$P_t^{\text{adj}} = \frac{P_t}{d^k}, \quad d = (1 + TD_{\text{annual}})^{1/252},$$

gdzie k oznacza liczbę dni od momentu rozpoczęcia notowań ETF.

Tak skorygowana seria jest następnie skalowana w punkcie łączenia w celu zapewnienia ciągłości z rzeczywistymi notowaniami ETF.


Do utworzenia benchmarku przyjęto **trzecie podejście**, ponieważ pozwala ono uchwycić kumulatywny charakter błędu odwzorowania, przy jednoczesnym zachowaniu prostoty i stabilności estymacji oraz pełnej zgodności z obserwowanymi danymi ETF po dacie jego debiutu.




Rysunek 13: Porównanie hybrydowego benchmarku z indeksem SP500TR i SP500.

Poniżej przedstawiono wizualizację dwóch okresów hybrydowego indeksu:

- **przed debiutem ETF** – historyczne notowania odtworzone na podstawie SP500TR z uwzględnieniem tracking difference.
- **po debiucie ETF** – hybrydowy indeks pokrywa się z ETF-em.



Rysunek 14: Hybrydowy indeks S&P 500 w okresie przed debiutem funduszu ETF (2000–2010).




Rysunek 15: Hybrydowy indeks S&P 500 oraz notowania ETF po debiucie funduszu (2010–2020).

S&P 500 Equal Weighted

Dla indeksu S&P 500 Equal Weighted dostępne są następujące tickery:

- **SP500EW** (^SP500EW, S&P 500 Equal Weight Index) — indeks cenowy (*price return*) równoważonej wersji S&P 500, gdzie każda spółka ma identyczny udział niezależnie od kapitalizacji.
- **ETF_EW** (RSP, Invesco S&P 500 Equal Weight ETF) — fundusz ETF replikujący indeks S&P 500 z równymi wagami, akumulujący dywidendy.

Na wykresie widać, że w ostatnich latach benchmark oparty na S&P 500 przewyższał ETF na S&P 500 Equal Weight. Jednak w latach przed 2018 strategia równych wag często osiągała podobne lub lepsze wyniki. Oznacza to, że relatywna efektywność podejścia equal-weight w dużej mierze zależy od siły największych spółek w indeksie.




Rysunek 16: Porównanie wyników indeksu S&P 500 oraz strategii Equal Weight.


Analogicznie do hybrydowego benchmarku dla S&P 500 ważonego kapitalizacją, można byłoby skonstruować benchmark hybrydowy dla wersji equal-weighted, uwzględniając wpływ dywidend zamiast błędu odwzorowania. W tym przypadku jednak ETF_EW (RSP) dysponuje najdłuższą dostępną historią — sięgającą 2003 roku — a przedłużenie jej wstecz napotyka na istotne ograniczenia: indeks dochodowy SP500EWTR nie jest dostępny w serwisie Yahoo Finance, SP500EW obejmuje krótszy okres, natomiast zastosowanie benchmarku cap-weighted jako substytutu zniekształciłoby charakterystykę strategii equal-weighted. Z tego powodu `benchmark_ew` ograniczony jest do okresu dostępności ETF_EW, a porównanie obu podejść prowadzone jest na wspólnym horyzoncie czasowym.

Ile danych brakuje?

Na poniższym wykresie widać, że w 1996 dane z Yahoo Finance pokrywają tylko 38%. Przy wyższym pokryciu można byłoby zastosować imputację brakujących danych, jednak jest ono na tyle małe, że konieczne będzie skorzystanie z dostawców danych, pokrywających spółki, które już nie są notowane.



Rysunek 17: Pokrycie danych cenowych spółek z indeksu S&P 500 w serwisie Yahoo Finance.



Rysunek 18: Przyczyny brakujących danych cenowych spółek z indeksu S&P 500 w serwisie Yahoo Finance.

2.3.2 Dane cenowe z EODHD

Na EODHD dostępnych jest kilka tickerów, dla których można korzystać z danych bezpłatnie. W przypadku akcji amerykańskich są to:

- AAPL.US
- TSLA.US
- VTI.US
- AMZN.US


```
1 demo_key = "demo"  
2 free_tickers = ["AAPL", "TSLA", "VTI", "AMZN"]  
3  
4 dataset.EODHD.download(  
5     tickers=free_tickers,  
6     api_key=demo_key,  
7 ) auto_adjust=False)
```

Listing 2: Pobieranie danych historycznych dla kilku darmowych tickerów z EODHD


Aby pobrać dane o spółkach wycofanych z giełdy trzeba zmapować tickery z submodułu sp500, na te, które istnieją na liście wycofanych tickerów w EODHD.

Ile danych brakuje?

Poniżej wykres przedstawiający pokrycie dla EODHD oraz diagram przyczyn brakujących danych. Widać, że pokrycie jest znacznie lepsze niż w przypadku Yahoo Finance, jednak nadal nie jest kompletne.



Rysunek 19: Pokrycie danych cenowych spółek z indeksu S&P 500 w serwisie EODHD.




Rysunek 20: Przyczyny brakujących danych cenowych spółek z indeksu S&P 500 w serwisie EODHD.

Widać, że pokrycie jest znacznie lepsze niż w przypadku Yahoo Finance, jednak nadal nie jest kompletne.

2.3.3 Połączenie danych z Yahoo Finance i EODHD

Po połączeniu danych z YahooFinance i EODHD wyniki analizy pokrycia nie wykazują różnicy. Oznacza to, że tych danych, których nie ma w EODHD, nie ma również w danych z YahooFinance.



Rysunek 21: Pokrycie danych cenowych spółek z indeksu S&P 500 po połączeniu danych z Yahoo Finance i EODHD.

2.3.4 Uzupełnienie brakujących danych

Aby ograniczyć wpływ błędu przeżywalności, należy uwzględnić zwroty z akcji spółek, dla których brakuje danych w zbiorze. Błąd ten zazwyczaj prowadzi do zawyżenia stóp zwrotu portfeli, co skutkuje nierealistycznymi wynikami i błędnymi wnioskami. Można go ograniczyć na dwa sposoby:

1. **Ograniczenie okna czasowego** — uwzględniać tylko okres, w którym pokrycie indeksu przekracza ustalony próg. W tym przypadku sensowne jest przyjęcie poziomu $\sim 80\%$ i rozpoczęcie analizy od 1998 roku. Skracza to okres badania jedynie o około 2 lata, a eliminuje fragment danych o niskim pokryciu.

2. **Imputacja brakujących danych** — uzupełnić brakujące obserwacje na podstawie stóp zwrotu indeksu oraz dostępnych danych pozostałych spółek.

W praktyce najlepiej połączyć oba podejścia.

Imputacja

Jednym ze sposobów imputacji jest wprowadzenie pomocniczego tickera, który reprezentuje spółki bez dostępnych danych. Następnie uwzględnia się go w modelach każdej strategii proporcjonalnie do poziomu pokrycia. Najpierw oblicza się średnią stopę zwrotu dla spółek z dostępnymi danymi, a następnie estymuje średni zwrot brakującej części tak, aby całość była spójna ze stopą zwrotu indeksu:

$$\Delta r_{\text{missing}} \approx \frac{\Delta r_{\text{index}} - \text{coverage} \cdot \Delta r_{\text{observed}}}{1 - \text{coverage}}$$


Przykład:

- $\Delta r_{\text{index}} = 100$
- $\text{coverage} = 0,75$
- $\Delta r_{\text{observed}} = 110$

$$\Delta r_{\text{missing}} = \frac{100 - 0,75 \cdot 110}{1 - 0,75} = \frac{100 - 82,5}{0,25} = 70$$


Niestety ten sposób nie jest idealny — przyjmujemy, że każda spółka w indeksie ma ten sam udział, co nie jest prawdą. Dlatego jako indeks przyjmujemy S&P 500 z równymi wagami (ETF_EW) przez jak najdłuższy okres, a następnie dołącza się klasyczne S&P 500 (SP500TR).

Można zauważyć, że stopy zwrotu spółek, których dane cenowe są dostępne, są większe niż stopy zwrotu indeksu, co jest wynikiem zamierzonym i dobrze odzwierciedla skalę błędu przeżywalności.



Rysunek 22: Porównanie indeksu S&P 500 z równymi wagami (ETF_EW) z średnim komponentem indeksu S&P 500 z pokryciem.

Można zauważyć, że w okresie bańki internetowej w okolicach roku 2000 sztucznie utworzony ticker wzrósł około 10-krotnie. Wynika to z ograniczenia metodologicznego: w tym okresie jako indeks stosowany jest SP500TR, który jest ważony kapitalizacją rynkową. Tymczasem średnia komponentów liczona jest z równymi wagami. Duże spółki technologiczne, dominujące w indeksie, rosły w tym czasie wyjątkowo szybko — stąd indeks systematycznie przewyższał średni komponent. Formuła imputacji błędnie interpretuje tę różnicę jako zwrot brakujących spółek, zawyżając wartość syntetycznego tickera. Dlatego warto ograniczyć zakres badania do okresu po 2001 roku.



Rysunek 23: Porównanie indeksu S&P 500 z równymi wagami (ETF_EW) z średnim komponentem indeksu S&P 500 z pokryciem wraz z syntetycznym tickerem reprezentującym brakujące dane.

3 Tworzenie strategii

Przy doborze portfeli inwestycyjnych jednym z kluczowych parametrów jest **liczba spółek wchodzących** w ich skład. Liczba ta może być zmienna — co często występuje w portfelach aktywnie zarządzanych — lub stała, co jest typowe dla portfeli dobieranych automatycznie według określonych reguł.

Za optymalną równowagę pomiędzy dywersyfikacją a koncentracją portfela uznaje się zazwyczaj od 10 do 20 spółek. Zbyt duża liczba walerów może prowadzić do osiągania stóp zwrotu zbliżonych do indeksu rynkowego, a często nawet niższych. Z kolei nadmierna specjalizacja powoduje, że wyniki pojedynczych spółek mają zbyt duży wpływ na wartość całego portfela, zwiększając jego ryzyko.

W dalszej części pracy, przy analizie poszczególnych strategii, przyjęto środkową wartość tego przedziału, czyli portfel składający się z $N = 15$ spółek.

Kolejnym analizowanym parametrem jest **częstotliwość doboru** portfela, rozpatrywana w wariantach miesięcznym, kwartalnym oraz rocznym. Każda z tych częstotliwości wiąże się z inną równowagą pomiędzy szybkością reakcji na zmiany rynkowe a kosztami oraz stabilnością portfela. W ramach pracy przeprowadzone zostaną testy dla każdego z rozważanych wariantów.


Należy zaznaczyć również, że rzeczywiste stopy zwrotu byłyby niższe,

szczególnie dla comiesięcznego doboru ze względu na koszty zmiany składu portfela.

Ekstremalne dzienne zwroty są odrzucane dla obu strategii, gdyż są one spowodowane błędami w zbiorze danych.

3.1 Strategia losowa

Najprostszą strategią, którą można przetestować jest strategia losowa, która losowo dobiera daną liczbę spółek cyklicznie.



Rysunek 24: Wyniki strategii losowej z różnymi częstotliwościami doboru w porównaniu z benchmarkiem S&P 500.

Można zauważyć, że strategia losowa dla częstszego doboru radzi sobie wyraźnie gorzej dla doboru miesięcznego i rocznego od benchmarku. Dla doboru kwartalnego — wyraźnie lepiej, co budzi wątpliwości co do jakości zbioru danych.

3.2 Strategia Monte Carlo

W przypadku metody Monte Carlo dochodzi kolejny czynnik — **okno wstecz**, które przyjąłem za rok, a więc w przybliżeniu 252 dni handlowych.

W poniższej strategii Monte Carlo to losowanie wielu portfeli, a nie symulacja ścieżek cen dla pojedynczych spółek. Dla każdej daty rebalansu wybiera się aktywne spółki z indeksu i zostawia te z wystarczającą liczbą obserwacji w oknie wstecz. Dla każdej spółki liczę średni dzienny zwrot i zmienność, po


czym losuje się określoną liczbę portfeli (przyjęto: 500) po N spółek. Wybrany portfel to ten o najwyższym współczynniku Sharpe'a [17], obliczanym według wzoru:

$$S = \frac{\mu - r_f}{\sigma}$$

gdzie:

- S – współczynnik Sharpe'a,
- μ – średnia stopa zwrotu portfela w danym okresie,
- r_f – średnia stopa zwrotu wolna od ryzyka w danym okresie,
- σ – odchylenie standardowe stopy zwrotu portfela w danym okresie.

W tej pracy przyjmuję $r_f = 0$, ponieważ celem jest jedynie relatywne porównanie portfeli, co sprowadza wskaźnik do ilorazu średniego zwrotu i zmienności




Rysunek 25: Wyniki strategii Monte Carlo z różnymi częstotliwościami doboru w porównaniu z benchmarkiem S&P 500.

W przypadku strategii opartej na Monte Carlo również to dobór kwartalny daje najlepsze wyniki. Wynik zbliżony, ale lekko powyżej benchmarku osiąga dobór miesięczny, co jest dosyć zrozumiałe - to dosyć krótki okres dla inwestowania w akcje.

3.3 Strategia najwyższego współczynnika Sharpe’a

W tej strategii, zamiast losować portfele, wybieramy N spółek, które w oknie wstecznym miały najwyższy indywidualny współczynnik Sharpe’a. A więc również nie jest to symulacja ścieżek cen dla pojedynczych spółek, a uproszczenie, które w teorii powinno dawać podobne wyniki. Jest to podejście bardziej deterministyczne, które faworyzuje historycznie „najlepsze” spółki niż losowanie portfeli. Parametry pozostają bez zmian.




Rysunek 26: Wyniki strategii najwyższego współczynnika Sharpe’a z różnymi częstotliwościami doboru w porównaniu z benchmarkiem S&P 500.

Tym razem to dobór roczny okazał się dużo lepszy niż benchmark. Dobór kwartalny daje wyniki porównywalne z benchmarkiem, natomiast miesięczny ponownie dużo gorzej.

Ponownie - te wyniki strategii również należy brać z ostrożnością. W takim wypadku dobrym pomysłem może okazać się porównanie każdej z tych 3 strategii dla doboru, w którym wszystkie dawały dobre w porównaniu z benchmarkiem zwroty, a więc doboru kwartalnego.

3.4 Porównanie strategii



Rysunek 27: Porównanie wyników wszystkich trzech strategii z doбором kwartalnym w porównaniu z benchmarkiem S&P 500.

Spośród analizowanych strategii najlepsze wyniki osiągnęła strategia Monte Carlo, której końcowa wartość przekroczyła 1500 (przy wartości początkowej równej 100). Dla porównania strategia losowa osiągnęła około 1200, natomiast strategia najwyższego współczynnika Sharpe’a około 1000. Wszystkie strategie znacząco przewyższyły benchmark, którego końcowa wartość wyniosła około 800. Ze względu na zaskakująco dobre wyniki strategii losowej przy rebalansowaniu kwartalnym, może stanowić ona lepszy punkt odniesienia niż sam benchmark.

Przewagę strategii Monte Carlo bazującej na losowaniu całych portfeli można tłumaczyć korzyściami płynącymi z dywersyfikacji. W tej metodzie spośród wielu losowo wygenerowanych portfeli wybierany jest ten o najwyższym współczynniku Sharpe’a, uwzględniającym zarówno oczekiwaną stopę zwrotu, jak i ryzyko całego portfela. Dzięki temu możliwe jest znalezienie kombinacji spółek, których wzajemne korelacje prowadzą do obniżenia zmienności portfela przy zachowaniu wysokich stóp zwrotu. Z kolei strategia oparta na wyborze N spółek o najwyższym historycznym współczynniku Sharpe’a nie uwzględnia zależności pomiędzy aktywami. Może to skutkować koncentracją portfela w spółkach o podobnym profilu ryzyka lub należących do tych samych sektorów, ograniczając efekty dywersyfikacji i prowadząc do słabszych wyników inwestycyjnych.

Tabela 3: Porównanie współczynników Sharpe’a i wartości końcowych dla poszczególnych strategii i częstotliwości doboru portfela.

Strategia	Współczynnik Sharpe’a	Wartość końcowa
Best Sharpe (Yearly)	0.6589	2184.42
Monte Carlo (Quarterly)	0.6379	1577.00
Benchmark	0.5620	816.18
Random (Quarterly)	0.5532	1168.41
Monte Carlo (Yearly)	0.5285	973.65
Best Sharpe (Quarterly)	0.5285	1020.34
Monte Carlo (Monthly)	0.4043	462.19
Best Sharpe (Monthly)	0.4037	481.39
Random (Yearly)	0.3071	301.06
Random (Monthly)	0.2485	214.02

Tabela współczynników Sharpe’a rozszerza obraz o pozostałe częstotliwości doboru. Patrząc tylko na dobór kwartalny, Monte Carlo osiąga najwyższy współczynnik Sharpe’a ($\sim 0,64$) spośród trzech strategii, wyprzedzając strategię losową ($\sim 0,55$) i strategię najwyższego współczynnika Sharpe’a ($\sim 0,53$), co jest spójne z wykresem.

W szerszym zestawieniu najwyższy współczynnik Sharpe’a osiąga roczna strategia najwyższego współczynnika Sharpe’a ($\sim 0,66$), co sugeruje, że ta strategia przy dłuższym horyzoncie rebalansowania lepiej kontroluje ryzyko. Razem z kwartalną strategią Monte Carlo osiąga wynik lepszy od benchmarku. Dobór miesięczny we wszystkich trzech strategiach wypada konsekwentnie najsłabiej, co jest spójne z wcześniejszymi obserwacjami.

4 Podsumowanie

4.1 Obserwacje, ograniczenia i wnioski

Projekt składał się z **dwóch głównych etapów** - utworzenia zbioru danych oraz opracowania i przetestowania strategii inwestycyjnych. Pierwszy z nich okazał się znacznie bardziej czasochłonny i złożony, ale jednocześnie kluczowy dla całego przedsięwzięcia, ponieważ bez odpowiedniej jakości danych wyniki strategii byłyby mało reprezentatywne. **Trudność** tego etapu wynikała z faktu, że żadne z wykorzystanych źródeł nie zapewniało pełnego pokrycia danych, a w przypadku serwisu EODHD zwiększanie pokrycia dla brakujących tickerów wymagało analizowania historii spółek i ręcznego mapowania ich oznaczeń.

Pomimo że celem projektu nie było pokonanie benchmarku (Sharpe $S \approx 0,56$), udało się to osiągnąć w przypadku dwóch utworzonych strategii:

1. Strategii najwyższych współczynników Sharpe’a przy doborze rocznym (Sharpe $S \approx 0,65$),
2. Strategii Monte Carlo na portfelach przy doborze kwartalnym (Sharpe $S \approx 0,63$).

Rezultaty te nie gwarantują jednak, że strategie przynosiłyby lepsze wyniki niż inwestowanie w szeroki indeks akcji, np. indeks S&P 500, z kilku powodów:

1. Najbardziej fundamentalny z nich dotyczy **jakości danych**. Dane pobrane z obu serwisów nie mają pełnego pokrycia, co wprowadza błąd wyprzedzania, a próby jego ograniczenia również obarczone są niepewnością. Dodatkowo w utworzonym zbiorze danych mogą występować błędy wynikające ze sklejenia szeregów czasowych z dwóch źródeł, nieuwzględnienia splitów i scaleń akcji lub niejednolitego pokrycia danych w czasie. W przypadku nietypowych, skrajnych dziennych zmian cen, będących oczywistymi błędami danych, ich wpływ nie był uwzględniany podczas testowania stóp zwrotu portfeli.
2. Fakt, że kwartalna **strategia losowa** daje lepsze zwroty niż benchmark jest sygnałem ostrzegawczym.
3. Nie ma gwarancji, że przyjęty **historyczny skład indeksu S&P 500** jest poprawny.
4. Nawet przy założeniu braku wpływu powyższych czynników, historyczne wyniki strategii nie gwarantują podobnych rezultatów w przyszłości. **Przeszłe stopy zwrotu nie stanowią gwarancji przyszłych wyników**, a rynek finansowy podlega ciągłym zmianom.

4.2 Przemyślenia i rozszerzenia

Sam projekt docelowo miał być bardziej rozbudowany i skoncentrowany na budowie strategii inwestycyjnych niż na przygotowaniu zbioru danych, jednak w praktyce ten drugi element okazał się niezbędny dla poprawnego działania całości i ostatecznie przeważał. Z perspektywy czasu uważam, że w tego typu projektach warto jak najszybciej zbudować minimalną, działającą wersję systemu, nawet jeśli początkowo jest ona mocno uproszczona.

Moim wnioskiem z pracy nad projektem jest to, że bardziej efektywne jest **podjęcie iteracyjne** - rozpoczęcie od najprostszej wersji pipeline'u danych i strategii, a następnie ich stopniowe rozszerzanie. Pozwala to szybciej uzyskiwać pierwsze rezultaty, lepiej rozumieć ograniczenia systemu oraz sprawniej identyfikować kluczowe problemy.

W obecnym podejściu prace były realizowane w **sposób sekwencyjny**, z naciskiem na maksymalne dopracowanie kolejnych etapów przed przejściem do następnych. Z perspektywy projektu okazało się to mniej elastyczne i wydłużyło moment uzyskania działających rezultatów. W przyszłości bardziej naturalne wydaje się rozpoczęcie od prostego rdzenia systemu, a następnie jego stopniowe rozwijanie w kierunku elementów najbardziej wpływających na jakość wyników.

Istniejący projekt stanowi solidną bazę, którą można w przyszłości **rozszerzyć** o bardziej zaawansowane podejścia do budowy strategii inwestycyjnych. Naturalnym kierunkiem dalszego rozwoju jest uwzględnienie metod opartych na analizie technicznej oraz fundamentalnej i innych danych o spółkach, a także wykorzystanie bardziej złożonych technik uczenia maszynowego do selekcji spółek i optymalizacji portfela.

Literatura

- [1] Wikipedia, *S&P 500*, dostępny w Internecie: https://pl.wikipedia.org/wiki/S%26P_500 [dostęp: 2026-06-07].
- [2] Stooq, *S&P 500 – wykres 50-letni (SPX)*, dostępny w Internecie: <https://stooq.com/q/?s=%5Espx&c=50y&t=c&a=lg&b=0> [dostęp: 2026-06-07].
- [3] Forex, *Trading the S&P 500*, dostępny w Internecie: <https://www.forex.com/en-au/index-trading/trading-the-sp-500/> [dostęp: 2026-06-07].
- [4] Seeking Alpha, *2026 Market Outlook: The S&P 500 Illusion And The Small-Cap Pivot*, dostępny w Internecie: <https://seekingalpha.com/article/4856133-2026-market-outlook-the-s-and-p-500-illusion-and-the-small-cap-pivot> [dostęp: 2026-06-07].
- [5] TradeThatSwing, *Average Historical Stock Market Returns for S&P 500*, dostępny w Internecie: <https://tradethatswing.com/average-historical-stock-market-returns-for-sp-500-5-year-up-to-150-year-averages/> [dostęp: 2026-06-07].

- [6] S&P Global, *SPIVA® U.S. Year-End 2025*, dostępny w Internecie: <https://www.spglobal.com/spdji/en/spiva/article/spiva-us/> [dostęp: 2026-06-07].
- [7] DALBAR, *Quantitative Analysis of Investor Behavior (QAIB) 2024*, dostępny w Internecie: <https://www.dalbar.com/press-release/investors-missed-the-best-of-2024s-market-gains-latest-dalbar-investor-behavior-report-finds/> [dostęp: 2026-06-07].
- [8] Barber, B. M., & Odean, T., *Trading Is Hazardous to Your Wealth: The Common Stock Investment Performance of Individual Investors*, dostępny w Internecie: https://faculty.haas.berkeley.edu/odean/papers%20current%20versions/individual_investor_performance_final.pdf [dostęp: 2026-06-07].
- [9] Graham, B., *The Intelligent Investor: The Definitive Book on Value Investing*
- [10] MSCI, *MSCI World Index*, dostępny w Internecie: <https://www.msci.com/indexes/index/990100> [dostęp: 2026-06-07].
- [11] MarketScreener, *S&P 500 ETF Components Heatmap*, dostępny w Internecie: <https://www.marketscreener.com/quote/index/S-P-500-4985/heatmap/> [dostęp: 2026-06-07].
- [12] fja05680, *sp500 - S&P 500 historical components and changes*, GitHub: <https://github.com/fja05680/sp500> [dostęp: 2026-06-07].
- [13] Wikipedia, *List of S&P 500 companies*, dostępny w Internecie: https://en.wikipedia.org/wiki/List_of_S%26P_500_companies [dostęp: 2026-06-07].
- [14] Clenow, A. F., *Trading Evolved: Anyone Can Build Killer Trading Strategies in Python*, 2019.
- [15] Yahoo Finance, dostępny w Internecie: <https://finance.yahoo.com/> [dostęp: 2026-06-07].
- [16] Ran Aroussi, *yfinance - Yahoo! Finance market data downloader*, GitHub: <https://github.com/ranaroussi/yfinance> [dostęp: 2026-06-07].
- [17] Wikipedia, *Wskaźnik Sharpe'a*, dostępny w Internecie: https://pl.wikipedia.org/wiki/Wska%C5%BAnik_Sharpe%E2%80%99a [dostęp: 2026-06-12].